

Name: Davood Salemi Gomari

Student ID: 40307074

Course: Algorithm Design

تعریف مسئله (Problem Definition)

هدف خلاصه‌سازی یک متن با رویکردی ترکیبی است. ابتدا از یک الگوریتم کلاسیک همانند Text Rank که بر پایه Page Rank می‌باشد برای تولید خلاصه اول استفاده می‌کنیم. سپس از یک مدل LLM جهت تولید خلاصه دوم و در نهایت یک الگوریتم طراحی می‌کنیم که این دو خلاصه را با یکدیگر ترکیب کند.

ورودی: متن T شامل n جمله $(S = \{s_1, s_2, \dots, s_n\})$

خروجی: زیرمجموعه‌ای از جملات $S' \subset S$ به طوری که $|S'| \ll |S|$ و S' بیشترین اطلاعات و معنای متن اصلی را حفظ کرده باشد و در عین حال کوتاه (خلاصه) باشد.

تحلیل

- نوع مسئله: گراف و بهینه‌سازی
- سختی: پیدا کردن بهترین خلاصه از نظر تئوری $NP-Hard$ است اما به کمک روش‌های تقریبی ($Heuristic$) و مبتنی بر گراف این مشکل حل می‌شود.
- نقش LLM : در این مسئله مدل مولد زبانی به عنوان یک معیار برای امتیازدهی مجدد به جملات انتخاب شده توسط الگوریتم کلاسیک استفاده می‌شود.

طراحی الگوریتم‌ها (Algorithm Design)

الگوریتم ۱: TextRank (رویکرد کلاسیک)

این الگوریتم متن را به یک گراف وزن‌دار تبدیل می‌کند.

۱. گره‌ها: هر جمله یک گره در گراف است.

۲. یال‌ها: وزن بین دو جمله (w_{ij}) نشان‌دهنده میزان شباهت آن‌هاست. در اینجا از معیار Cosine

Similarity بین بردارهای Embedding جملات (TF-IDF) استفاده می‌شود.

$$w_{ij} = Sim(s_i, s_j) = \frac{v_i \cdot v_j}{\|v_i\| \|v_j\|}$$

با اجرای الگوریتم Page Rank روی این گراف، جملات مهم یافت می‌شوند. فرمول بازگشتی:

$$PR(s_i) = (1 - d) + d \sum_{s_j \in In(s_i)} \left(\frac{w_{ji}}{\sum_{s_k \in Out(s_j)} w_{jk}} \times PR(s_j) \right)$$

که d فاکتور میرایی بوده و معمولا 0.85 در نظر گرفته می‌شود.

TF-IDF یک تکنیک آماری است که اهمیت هر کلمه در جمله را مشخص می‌کند. مثلاً کلماتی مانند «است» یا «که» و ... وزن کمی می‌گیرند ولی کلمات خاص مانند «الگوریتم» یا «هوش مصنوعی» وزنی زیاد می‌گیرند. نتیجه نهایی آن یک بردار عددی است.

$$TF(w, s) = \frac{\# \text{ occurrence of word } w \text{ in sentence } s}{|s|}$$

$$DF(w) = \# \text{ sentences that contains the word } w$$

$$IDF(w) = \log \left(\frac{N}{DF} \right), \quad TFIDF(w, s) = TF(w, s) \times IDF(w)$$

LLM برای تولید خلاصه مرجع:

در این مرحله از یک LLM برای تولید خلاصه دوم مرجع استفاده می‌کنیم.

$$S_{ref} = LLM(D)$$

الگوریتم ۲: ترکیب خلاصه‌ها (Hybrid Merger)

برای تولید خلاصه نهایی نیاز به امتیازدهی دوباره جملات داریم. امتیاز جدید هر جمله ($Score(s_i)$) ترکیب خطی از امتیاز الگوریتم TextRank و امتیاز معنایی LLM است.

چون مقیاس دو امتیاز متفاوت است، ابتدا نیاز به نرمال‌سازی داریم:

$$\widehat{PR}(s_i) = \frac{PR(s_i)}{\max_j PR(s_j)}$$

سپس هر یک از جملات S_{ref} و تمام جملات اصلی s_i توسط یک مدل Transformer مانند BERT به فضای برداری معنایی نگاشت می‌شوند:

$$e_{ref} = Embed(S_{ref}), \quad e_i = Embed(s_i)$$

برای محاسبه شباهت معنایی از معیار *Cosine Similarity* استفاده می‌کنیم:

$$Sim_{ref}(s_i) = \frac{e_i \cdot e_{ref}}{\|e_i\| \|e_{ref}\|}$$

سپس امتیاز نهایی جمله S_i به صورت زیر محاسبه می‌شود:

$$Score(s_i) = \alpha \cdot \widehat{PR}(s_i) + (1 - \alpha) \cdot Sim_{ref}(s_i)$$

پارامتر α میزان اهمیت نتیجه الگوریتم *TextRank* و خروجی *LLM* را تعیین می‌کند.

در نهایت K با بیشترین امتیاز انتخاب می‌شوند و بر مبنای محل مشاهده در متن مرتب می‌شوند که پیوستگی متن خلاصه متناسب با متن اصلی باشد.

تحلیل پیچیدگی

فرض کنید:

- N تعداد جملات متن
- L میانگین طول هر جمله (میانگین تعداد کلمات)
- D ابعاد بردار ویژگی TF-IDF
- k تعداد تکرارهای الگوریتم PageRank برای همگرایی

پیچیدگی زمانی

پیش پردازش: توکن‌بندی و حذف حرف‌های اضافی Stop از جملات.

$$O(NL)$$

ساخت گراف: شباهت هر جمله با جملات دیگر باید محاسبه شود. طول هر بردار جمله نیز D بعدی است.

$$O(N^2D)$$

اجرای **PageRank**: از آنجایی که گراف کامل است، تعداد یال‌های از مرتبه $E \sim O(N^2)$ می‌باشد. در هر تکرار این الگوریتم نیاز است که برای هر گره، تمام یال‌های ورودی بررسی شوند.

$$O(kN^2)$$

محاسبه جمله مرجع (توسط *LLM*) و ترکیب: تولید بردارهای معنایی $O(ND)$ و مقایسه آن‌ها نیز

$O(ND)$ زمان نیاز دارد. در نتیجه:

$$O(ND)$$

پیچیدگی زمانی کل

اگر مقادیر D و k و L را نسبت به N ثابت در نظر بگیریم، خواهیم داشت:

$$T(N) = O(NL) + O(N^2D) + O(kN^2) \approx O(N^2)$$

پیچیدگی فضایی

ذخیره ماتریس مجاورت: نیاز به ذخیره N^2 عدد اعشاری داریم.

$$O(N^2)$$

ذخیره بردارها: نیاز به ذخیره N بردار با طول D داریم.

$$O(ND)$$

پیچیدگی فضایی کل:

$$O(N^2)$$

نتیجه گیری

الگوریتم پیشنهادی دارای پیچیدگی زمانی و فضایی $O(N^2)$ است.

- مزیت: برای متون خبری و مقالات علمی کوتاه که $N < 500$ مناسب است.
- ضعف: برای کتابهای طولانی که $N > 10000$ به مشکل خواهد خورد و نیاز به تکنیک‌هایی همانند استفاده از ماتریس‌های خلوت (*Sparse Matrices*) است.